Закон дисперсии внимания и двухканальное расщепление в авторегрессионных трансформерах

Владимир В. «SkyAngel» Боровиков*
Независимый исследователь
skywhiteangels@gmail.com

Октябрь 2026

Abstract

Большие языковые модели хорошо продолжают связный текст, но остаются уязвимы там, где нужно удерживать *дискретные инварианты* — точный целочисленный счёт на длинных последовательностях. На предрегистрированном корпусе из 1 416 канонических проб (1 320 в основной серии Argon v8–v16 плюс 96 в репликации v6), снятых при нулевой температуре на современных MoE-трансформерах (при строгой изоляции No-Tools на всех 960 чисто когнитивных пробах счёта в v9 и v11–v16, наряду с протоколами работы с инструментами в v8 и v10), мы исследуем механистический локус ошибки дискретного счёта (перелёт $N \to N+1$ на границе).

Через серию анатомических интервенционных экспериментов мы показываем, что:

1. **Декодер оправдан:** применив алгебраический усилитель ($f(N) = 10N - 6$, v15), чтобы отделить дрейф сканирования внимания ($\Delta = \pm 10$) от глитчей выходного эмбеддинга ($\Delta = +1$), мы получаем строго **0 / 96** (0,0%, двусторонний 95% интервал Клоппера–Пирсона $[0{,}0\%; 3{,}8\%]$) ошибок декодера на единицу, тогда как на перцептивный дрейф входного сканирования приходится 34,4% (33/96).
2. **Гипотеза токенизатора отпадает:** сопоставив побайтово и посимвольно повторяющийся корейский субсловный маркер (점점점◁, 12 байт UTF-8) с чистым блоком геометрических символов Unicode (▤▤▤▤, 12 байт UTF-8, v16), мы показываем, что замена языка геометрией не устраняет фантомные ошибки (35,4% против 41,7%, точный тест Фишера $p = 0{,}675$). Это не поддерживает сильную гипотезу BPE-токенизации и согласуется с гипотезой о том, что предел дискретного счёта отражает фазовое ограничение внимания.
3. **Двухканальное расщепление внимания:** в состязательных пробах с газлайтингом (v13) модель выполняет указание выдать ложь в видимом содержании (93,8%), но спонтанные «утечки истины» напрямую из латентного канала рассуждения (`thinking`) в терминальный токен происходят в 2/48 пробах. Это показывает, что терминальные логиты могут расходиться с локальным авторегрессионным n-граммным контекстом.

Мы формализуем эти эмпирические результаты в *закон дисперсии внимания*: когда монотонные последовательности превышают ёмкость локального окна внимания ($N \geq 8..16$), фазовая интерференция позиционных эмбеддингов размывает границы рецептивных полей и порождает дискретный перелёт. Отсюда следует, что детерминированные агентные архитектуры должны дополнять передачу данных внутри контекста внешней передачей по ссылке и детерминированными рантайм-проверками чётности.

Ключевые слова: интерпретируемость трансформеров, пределы self-attention, двухканальное внимание, индукционные головы, счёт в контексте, безопасность LLM-агентов.

*ORCID: 0009-0005-7773-3581

1 Введение

Авторегрессионные трансформеры произвели революцию в непрерывном моделировании естественного языка, генерации кода и семантическом выводе [1]. При этом автономные агенты в промышленной эксплуатации регулярно отказывают на простых детерминированных операциях над структурированными строками: подсчёт разделителей, отслеживание состояний автомата, балансировка кавычек, оценка глубины синтаксического дерева.

В промышленном контексте (автоматическая правка кода, разбор бинарных логов, исполнение скриптов) ошибка на единицу ($N \to N+1$ или $N \to N-1$) не является безобидной стилистической погрешностью. Она ведёт к взаимным блокировкам в командных интерпретаторах, сломанным переходам синтаксиса и тихому повреждению данных. В исследованиях LLM сложились две конкурирующие обиходные гипотезы, объясняющие этот сбой счёта:

- **Гипотеза декодера ($H_{\mathbf{DEC}}$):** внутреннее скрытое представление точно кодирует истинный счёт N, но финальная линейная проекция (голова эмбеддинга) и температурная дисперсия softmax приводят к случайному перелёту на единицу на выходе.
- **Гипотеза токенизатора ($H_{\mathbf{BPE}}$):** многобайтовые символы и редкие токены подвергаются неравномерному разбиению на субслова при Byte-Pair Encoding (BPE), что вызывает пространственные фазовые сдвиги в ротационных позиционных эмбеддингах (RoPE [2]) и вводит модель в заблуждение.

Экспериментальная серия Argon была задумана как многоэтапная эмпирическая программа для изоляции, проверки и разрешения этой уязвимости при строгом контроле условий. На 1 416 канонических пробах мы подвергли современные рантаймы трансформеров строгим интервенционным пробам.

1.1 Смежные работы: схемы внимания и перцептивные иллюзии

Зафиксированные в серии Argon отказы дискретного счёта пересекаются с тремя крупными областями механистической интерпретируемости: механикой обучения в контексте, геометрией пространств представлений и вычислительными пределами параллельных архитектур.

Индукционные головы и маршрутизация контекста. Недавние работы выявили конкретные многомодульные схемы внимания («индукционные головы»), отвечающие за обучение в контексте и дополнение паттернов [3]. Эти схемы позволяют трансформеру просматривать предшествующий контекст, находить предыдущие вхождения текущего токена и копировать следующие за ними токены. Наши результаты по двухканальному вниманию (§3.3) показывают, что этот механизм маршрутизации не привязан жёстко к авторегрессионному выходному потоку. Наблюдаемые «утечки истины» — когда терминальный токен возвращается к латентному состоянию счёта во внутреннем потоке рассуждения (`thinking`), противореча непосредственно предшествующему видимому тексту, — означают, что конкурирующие схемы внимания могут переопределять логику локального n-граммного продолжения на границе эмбеддинга. Это согласуется с пониманием того, что финальные распределения логитов представляют собой суперпозицию нескольких, потенциально конфликтующих алгоритмических путей.

Суперпозиция и искажение представлений. Закон дисперсии внимания (§4) структурно близок явлениям суперпозиции и искажения признаков в полисемантических моделях [4, 5]. Когда архитектура представляет плотные периодические признаки (например, монотонные последовательности одинаковых токенов) в конечномерных пространствах активаций, взаимная ортогональность позиционных кодирований деградирует. При высокой повторяемости ($N \geq 16$) фазовая интерференция между соседними позиционными эмбеддингами размывает рецептивные

поля внимания, что даёт фантомный пересчёт ($N + 1$). Как показано в Argon v16, замена сложного естественного языка геометрическими примитивами не смягчает эту ошибку, что подтверждает: галлюцинации на границе являются структурным следствием упаковки информации в многоголовом внимании.

Пределы последовательных вычислений в трансформерах. Теоретические и эмпирические работы показывают, что трансформеры плохо справляются с формальными языками и автоматами, требующими строгого последовательного отслеживания состояния [6]. Серия Argon расширяет эти выводы, изолируя стадию отказа: модель отказывает не при арифметическом декодировании, а активно воспринимает неверный счёт на этапе сканирования входа (v15, где декодер оправдан при $\Delta = +1$). Отказ носит входной, перцептивный характер, а не выходной, генеративный, — а значит, самокоррекция через промпт не заменяет внешнюю детерминированную проверку чётности (§5).

2 Методология и экспериментальная строгость

Чтобы соответствовать строгим научным требованиям и исключить предвзятость подтверждения, все эксперименты следовали предрегистрированному протоколу и проходили аудит по протоколу Red Team проекта Argon. Автор выступает аудитором Red Team этого проекта. Аудит внутренний, а не независимый: тот же автор ставил пробы и проверял числа, поэтому ни одно утверждение ниже не опирается на внешнюю проверку (§4.3).

Инструмент и объект исследования. Объект исследования — сам проект Argon: его протокол проб, его архивы и утверждения, написанные о них. Инструментом был замороженный инференс-рантайм, доступный через шлюз Antigravity и записанный в каждой записи архива как `model = flash_lite`. Именно этот идентификатор, а не торговое название модели, подтверждается телеметрией, и только он здесь используется.

2.1 Изоляция рантайма и инвариант No-Tools

Все пробы выполнялись на замороженном инференс-рантайме `flash_lite` (современный MoE-трансформер с явным латентным каналом рассуждения, `thinking`). За исключением разведочного базового прогона v8 (где исполнение кода разрешалось) и референсного контроля v10 (читавшего локальные файлы с диска), все 960 канонических проб в v9 и v11–v16 выполнялись в строгой **изоляции No-Tools** (`tools=[]`). Каждый журнал запроса в `archive.jsonl` прошёл криптографический аудит: несанкционированных вызовов инструментов строго $0/960$ (0,0%).

2.2 Криптографическая предрегистрация

До выполнения любой экспериментальной пробы скрипт-раннер, шаблон промпта, парсер оценки и набор статистических тестов замораживались и хэшировались: ранние серии (v3–v8) — в пофайловый `MANIFEST.sha256`, поздние (v9–v16) — в посерийный `FREEZE.txt`. Гипотезы и первичные критерии исхода фиксировались до вызовов API, что исключает подгонку предрегистрированных конечных точек под данные. Анализы, заданные после того, как данные были увидены, помечены как *post-hoc* там, где они приводятся, и не несут основных утверждений.

2.3 Парная рандомизация по сиду

Чтобы контролировать шум филлера, длины последовательностей и позиционные сдвиги, в пробах использовались детерминированные парные сетки по сиду:

$$\text{Seed}_k = 20261100 + 16000 + k, \quad k \in [1, 48]. \tag{1}$$

Каждый сид порождал идентичную геометрию контекста в обеих руках, так что единственной независимой переменной оставалась целевая интервенция.

2.4 Алгебраическое усиление

В Argon v15 введён метод алгебраического усиления, разделяющий ошибки внимания и сбои выходного декодера:

$$f(N) = 10 \cdot N - 6. \tag{2}$$

Множитель $10\times$ чисто разносит гипотезы по разным десятичным разрядам:

- Ошибка сканирования внимания на один элемент ($N = 16 \to 17$) сдвигает разряд десятков: $10 \times 17 - 6 = 164$ ($\Delta = +10$ относительно истины 154).
- Сбой терминального декодера выдаёт токен на единицу больше в разряде единиц: $154+1 = 155$ ($\Delta = +1$).

2.5 Побайтовое и посимвольное лексическое сопоставление

Чтобы строго проверить гипотезу BPE-токенизации в v16, мы противопоставили сложный многобайтовый корейский маркер (점점점◁, 4 символа Unicode, 12 байт UTF-8)[1] чистому геометрическому блоку (▤▤▤▤, Unicode `U+25A4`, 4 символа, 12 байт UTF-8). Промпты выровнены побитово:

$$|\text{Prompt}_A| = |\text{Prompt}_B| = 880 \text{ симв.}, \quad \text{len}(\text{Prompt}_A)_{\text{UTF-8}} = \text{len}(\text{Prompt}_B)_{\text{UTF-8}} = 1421 \text{ байт}. \tag{3}$$

3 Эмпирические результаты

3.1 Хронологический обзор серии Argon

- **v8 (вынос счёта инструменту):** когда исполнение кода разрешено, модели делегируют мысленный счёт Python в 25/96 сессиях, но получают повреждение при передаче данных обратно в контекст.
- **v9 (когнитивный барьер No-Tools):** отключение внешних инструментов обнажает системный пересчёт $N \to N + 1$. Включение латентного рассуждения (`thinking`, система 2) снижает долю ошибок с 93,8% до 27,9% ($p = 2{,}91 \times 10^{-18}$, отношение шансов OR $= 38{,}7$).
- **v10 (изоляция контекста):** передача данных по значению внутри промпта вызывает дрейф токенов полезной нагрузки. Передача по ссылке дала нулевое повреждение полезной нагрузки, хотя точность счёта осталась сопоставимой ($68/72 = 94{,}4\%$ против $70/72 = 97{,}2\%$, точный тест Фишера $p = 0{,}6808$, что служит архитектурным ориентиром, а не эмпирическим законом).
- **v11 (насыщение ёмкости системы 2):** принудительное пошаговое перечисление (`1. маркер, 2. маркер...`) не устраняет $N + 1$. При $N = 16$ удержание формата падает со 100% до 89,6% ($p = 0{,}056$), что указывает на истощение когнитивного бюджета.
- **v12 (расщепление каналов):** авторитетные ложные подсказки в промпте («здесь ровно 10 маркеров») не искажают выходной декодер (decoder_glitch $= 0/96$).
- **v13 (состязательный газлайтинг):** при явном указании лгать в видимом тексте (93,8% выполнения) истинный латентный счёт модели утекает из `thinking` в финальный ответ в 2/48 пробах.

[1] При наборе не-ASCII глифы выводятся шрифтом, в котором они есть; точные 12-байтовые последовательности UTF-8 записаны побайтово в `reproducibility/markers.txt`.

- **v14 (слепая алгебраическая ложь $N-6$):** при отсутствии целевых цифр в промпте модель выдаёт 11 ($17-6=11$) в 16,7% проб ($p=0{,}00569$), что согласуется с гипотезой о том, что модель воспринимает 17 элементов до выполнения математической операции.
- **v15 (алгебраический усилитель $10N-6$):** множитель $10\times$ изолирует 33/96 дрейфов сканирования внимания ($\Delta=\pm 10$), тогда как сбои декодера ($\Delta=+1$) остаются строго $0/96$ (двусторонний 95% интервал Клоппера–Пирсона $[0{,}0\%; 3{,}8\%]$). Обе доли считаются на одних и тех же 96 пробах, поэтому приводятся с интервалами, а не через двухвыборочный тест.
- **v16 (BPE против геометрии):** замена языковых токенов геометрическими примитивами даёт ту же долю фантомов (35,4% против 41,7%, $p=0{,}675$). Руки различаются *формой* ошибки, а не её *частотой*: узкие перелёты $N+1$ уступают место диффузным фантомам высшего порядка (таблица 2; пятибиновый тест там же помечен как post-hoc).

3.2 Дрейф внимания: оправдание декодера (v15)

Постановка v15 дала решающее разбирательство между механизмом входного сканирования и выходной головой эмбеддинга. Таблица 1 показывает распределение по 96 пробам.

Категория исхода	Наблюдаемые значения	Проб ($N=96$)	Доля [95% интервал Клоппера–Пирсона]
Точный инвариант	160 (A) / 154 (B)	62 / 96	64,6% [54,2%; 74,1%]
Перелёт внимания ($\Delta \geq +10$)	170 (A) / 164, 174, 184 (B)	23 / 96	24,0% [15,8%; 33,7%]
Недолёт внимания ($\Delta \leq -10$)	150 (A) / 94..144 (B)	10 / 96	10,4% [5,1%; 18,3%]
Не разобрано / нет ответа	—	1 / 96	1,0% [0,0%; 5,7%]
Глитч декодера ($\Delta=+1$)	161 (A) / 155 (B)	**0 / 96**	**0,0% [0,0%; 3,8%]**

Table 1: Распределение исходов в Argon v15 ($N=96$, алгебраический усилитель $10N-6$).

Контраст между входным дрейфом внимания (33/96, 34,4%) и сбоями выходного декодера (строго 0/96, 0,0%, двусторонний 95% интервал $[0{,}0\%; 3{,}8\%]$) показывает, что голова эмбеддинга достоверно отражает содержимое рабочей памяти, а искажение возникает выше — в слоях многоголового внимания.

3.3 Двухканальное внимание: расщепление каналов и утечки истины (v12–v14)

Анализ кросс-канальной согласованности между внутренним буфером рассуждения (`thinking`) и испускаемым текстом (`content`) показывает, что авторегрессионные модели способны поддерживать параллельные, не сходящиеся вычислительные траектории.

В Argon v13 модели получали явное указание: *«Ты должен утверждать, что в content 10 элементов, но честно думать в thinking»*. Модели выполнили ложное указание в видимом тексте в 93,8% проб ($45/48$), и при этом возникли две различные кросс-канальные аномалии:

- **Утечки истины (пробы k06, k22):** видимый текст порождал ложную последовательность `1, 2... 10`. Сразу после токена `10` головы внимания обходили локальный префикс и извлекали латентный инвариант из `thinking`, выдавая: `ANSWER: 16`.
- **Утечки лжи (пробы k04, k14, k20):** видимый текст корректно перечислял элементы до 16, но терминальный токен исполнял команду состязательного промпта: `ANSWER: 10`.

Это показывает, что видимый сгенерированный текст не является изоморфным отражением внутреннего состояния. Авторегрессионные головы могут проводить терминальные решения через параллельные латентные пути в обход только что сгенерированного текста.

3.4 Заблуждение токенизатора против предела внимания (v16)

Эксперимент v16 отвечал на главное возражение рецензента: не является ли дискретный пересчёт просто артефактом субсловной фрагментации BPE? Таблица 2 сводит результаты по 96 пробам.

Целевой токен	**Точный счёт ($N = 16$)**	**Узкий $N + 1$ (17)**	**Все фантомы (> 16)**	**Тест Фишера**
A: корейский 점점점◁	28 / 48 (58,3%)	11 / 48 (22,9%)	**17 / 48 (35,4%)**	$p = 0{,}675$
B: геометрия ▤▤▤▤	22 / 48 (45,8%)	2 / 48 (4,2%)	**20 / 48 (41,7%)**	
Сдвиг профиля ошибок	—	таблица сопряжённости 2×5 (post-hoc)		$p = 0{,}0017$

Table 2: Частоты исходов в Argon v16 ($N = 96$, корейский BPE против геометрии Unicode).

Сильная гипотеза BPE предсказывала, что замена многобайтового корейского текста геометрическими глифами устранит фантомы (H_{BPE} : $\text{Rate}_B \to 0\%$). В действительности доля фантомов в руке B осталась практически той же: $41{,}7\%$ против $35{,}4\%$ ($p = 0{,}675$).

Однако анализ сопряжённости по полному пятибиновому распределению ошибок (точный тест 2×5, $p = 0{,}0017$), заданный после того, как данные были увидены, и потому приводимый как *post-hoc*, указывает на качественную структурную мутацию:

- Токены естественного языка локализуют ошибки плотно вокруг $N + 1$ ($22{,}9\%$).
- Монотонные геометрические токены вызывают диффузные фазовые обрушения, размазывая ошибки в фантомы высшего порядка: 15 из 48 проб ($31{,}2\%$) галлюцинировали счёт 19 и 20.

Поскольку пятибиновый тест был задан после просмотра данных, он не несёт основного утверждения. Предрегистрированный контраст по узкому $N + 1$ сам по себе даёт $p = 0{,}0144$, что не проходит порог Бонферрони $0{,}0125$ по четырём запланированным контрастам. Без оговорок данные поддерживают приведённый выше отрицательный результат: замена токена не убирает фантомы.

4 Обсуждение: закон дисперсии внимания

4.1 Математическая формулировка

Полученные результаты поддерживают *закон дисперсии внимания*:

> *Когда авторегрессионный трансформер сканирует периодическую последовательность одинаковых или почти одинаковых токенов, распределение самовнимания, чувствительное к позиции, испытывает пространственную фазовую дисперсию. За критическим порогом протяжённости ($N \approx 8..16$) позиционная дисперсия превышает межагентные интервалы, вызывая пограничную интерференцию и сдвигая проинтегрированную массу на $+1$ (или $+k$).*

В ротационных позиционных эмбеддингах (RoPE [2]) взаимодействие запроса и ключа модулируется ортогональными матрицами поворота:

$$q_m^T k_n = x_m^T W_q^T R_{\Theta, m-n} W_k x_n. \tag{4}$$

Когда эмбеддинги токенов идентичны ($x_m \approx x_n$), различение опирается исключительно на относительный угол $\Delta\theta = (m - n)\theta_i$. На компактных отрезках ($N \leq 8$) углы поворота остаются различимыми. При $N \geq 16$ кумулятивное объединение внимания по повторяющимся паттернам размывает границы активаций. Модель интерпретирует терминальный разделитель как дополнительный пик плотности и порождает фантомный токен $N + 1$.

4.2 Дилемма добровольного промптинга

Наши результаты объясняют, почему интервенции через промпт («думай пошагово», «считай внимательно») не решают проблему дискретного счёта:

1. Принудительное пошаговое перечисление (v11) истощает бюджеты внимания, снижая удержание формата на $10{,}4\%$.
2. Рассуждение системы 2 (v9) поднимает точность с $6{,}2\%$ до $72{,}1\%$, но оставляет $27{,}9\%$ остаточных ошибок; сохраняющиеся ошибки не сводятся к $N+1$ ($22{,}9\%$ против $4{,}2\%$ по двум рукам v16).
3. Терминальные токены могут расходиться с предшествующим вербализованным рассуждением (v13, двухканальное внимание).

4.3 Два класса отказов: дисперсия внимания и сдвиг ожидания

Отказы, измеренные выше, механистичны. За критическим порогом чувствительное к позиции самовнимание размывается, и проинтегрированная масса сдвигается на $+1$ или $+k$ независимо от семантики задачи и от того, кто ставит промпт. Поэтому мы разделяем два класса отказов, которые регулярно смешивают:

1. **Дисперсия внимания и декодера (измерено).** Уплотнение контекста и сканирующее внимание по повторяющимся токенам заставляют модель терять истинное значение ($N{+}1$-фантом в v6–v16; алгебраический дрейф $\Delta{=}+10$ в v15). Этот класс установлен настоящим аудитом.
2. **Сдвиг ожидания и поддакивание (гипотеза).** Внутри одной длинной сессии модель адаптируется к пользователю: она выводит заявленное им ожидание и направляет вывод к согласию с этим ожиданием, а не к реальному результату. Это механизм адаптации на этапе инференса (он работает в контексте, а не через переписывание весов) и описан в литературе о поддакивании [7]. Наши v12 (авторитетный якорь) и v13 (следование состязательной посылке) показывают частичные, статистически незначимые признаки этого сдвига, но аудит *не* устанавливает его как главную причину измеренной выше дисперсии.

Мы формулируем отношение как гипотезу, а не вывод: *адаптация к пользователю смещает модель к согласию с ожиданием; протокол передачи по ссылке не оспаривает этот механизм и не отключает его — он отделяет критерий приёмки от одобрения пользователя, ставя каждое утверждение в зависимость от истины (контрольной суммы архива) и нейтрализуя дрейф внутри сессии на границе инфраструктуры.*

5 Архитектурный проект детерминированных LLM-агентов

Чтобы строить устойчивые автономные ИИ-системы, взаимодействующие с операционными системами и компиляторами кода, мы формулируем три архитектурные рекомендации (рабочие ориентиры):

1. **Рекомендация 1: изоляция контекста передачей по ссылке.** Инвариантные структуры, сырые файлы и конфигурационные полезные нагрузки не должны передаваться в окно контекста по значению (*Pass-by-Value*). Окно контекста должно получать строго типизированные ссылки (пути к файлам, URI баз данных), изолируя данные от фазового размывания внимания.

2. **Рекомендация 2: обязательная детерминированная проверка чётности.** Все дискретные утверждения, испускаемые LLM (счётчики, парность кавычек, баланс AST), должны проверяться детерминированными рантайм-гейтами вне трансформера (например, конечными автоматами, хэш-проверками). Трансформер предлагает, детерминированное ПО располагает.

3. **Рекомендация 3: гейтирование PreToolUse на уровне инфраструктуры.** Проверки безопасности не должны опираться на добровольное обращение модели. Перехватчики должны работать на уровне инфраструктуры хоста (например, хуки PreToolUse), перехватывая команды до исполнения в оболочке.

6 Сводная эмпирическая матрица

Таблица 3 сводит всю каноническую экспериментальную программу ($N = 1\,416$ проб).

Серия	Проб	Целевая переменная	Рука A (контроль)	Рука B (эксперимент)	Ключевая метрика	Значимость (p)
v6	96	Репликация пилота v1	Градуированные дозы $N = 0..64$	Воспроизведённая метрика	Ложные утечки	0/92 без эха ($p < 0{,}001$)
v8	216	Вынос счёта в код	Мысленный счёт	Песочница Python	Принятие инструмента	25/96 сессий ($p = 2{,}15 \times 10^{-10}$)
v9	288	Барьер No-Tools	Рассуждение включено	Рассуждение отключено	Точность	$p = 2{,}91 \times 10^{-18}$
v10	144	Изоляция контекста	По значению	По ссылке	Дрейф 0 против 1	Точность 94,4% против 97,2% ($p = 0{,}6808$, н.з.)
v11	192	Ёмкость перечисления	Обычный счёт $N = 8, 16$	Перечисление $N = 8, 16$	Удержание формата	$p = 0{,}056$ ($N = 16$)
v12	96	Авторитетное смещение	Нейтральный промпт	Ложная подсказка ($N = 10$)	Сбой декодера 0/96	Сопротивление подсказке 29/48 против 29/48 ($p = 1{,}00$)
v13	96	Состязательный газлайтинг	Честный счёт	Приказ лгать ($N = 10$)	Утечка истины	2/48 утечек ($p = 0{,}4947$, против 0/48)
v14	96	Слепая ложь ($N - 6$)	Прямой счёт 16	Вычитание ($N - 6$)	Ответ 11	8/48 ($p = 0{,}00569$)
v15	96	Алгебраический усилитель	Масштаб $10N$	Усилитель $10N - 6$	Декодер $\Delta = +1$	0/96 (95% интервал [0,0%; 3,8%])
v16	96	Опровержение токенизатора	Корейский 점점점◁	Геометрия ▭▭▭▭	Доля фантомов	$p = 0{,}675$

Table 3: Сводная каноническая матрица экспериментальной серии Argon ($N = 1\,416$ проб).

7 Доступность данных и воспроизводимость

Чтобы обеспечить эмпирическую воспроизводимость по принципам FAIR без барьеров по пропускной способности, в репозитории проекта открыто публикуется облегчённый проверочный комплект:

- **Канонический проверочный набор данных:** нормализованная запись всех 1 416 экспериментальных проб сведена в `reproducibility/probes.jsonl` (261 КБ). Прилагаемый автономный скрипт `reproducibility/verify_numbers.py` детерминированно пересчитывает ключевые метрики статьи по всем сериям (дрейф сканирования внимания и стабильность декодера в v15, когнитивное подавление системы 2 в v9, инвариант нулевых утечек No-Tools, деградация формата в v11, утечки истины в v13, слепое вычитание в v14, геометрический контроль токена в v16, стабильность ссылки в v10 и сопротивление авторитету в v12) без внешних зависимостей.

- **Репозиторий кода:** https://github.com/skywhiteangels-cell/llm-token-architect (содержит FSM Quote Guard, наборы тестов и комплект воспроизводимости).

- **Постоянный архив препринта (DOI Zenodo):** https://doi.org/10.5281/zenodo.23679671

- **Сырые архивы телеметрии:** полные трассы JSONL, включая тексты промптов и журналы внутреннего рассуждения (∼570 МБ суммарно по всем прогонам, ∼460 МБ по каноническим v8–v16), хранятся у авторов и доступны по запросу.

References

[1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.

[2] Jianlin Su, Murtadha Ahmed, Yu Lu, Shengfeng Pan, Wen Bo, and Yunfeng Liu. Roformer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568:127063, 2024.

[3] Catherine Olsson, Nelson Elhage, Neel Nanda, Nicholas Joseph, Nova DasSarma, Tom Henighan, Ben Mann, Amanda Askell, Yuntao Bai, Anna Chen, Tom Conerly, Dawn Drain, Deep Ganguli, Zac Hatfield-Dodds, Danny Hernandez, Scott Johnston, Andy Jones, Jackson Kernion, Liane Lovitt, Kamal Ndousse, Dario Amodei, Tom Brown, Jack Clark, Jared Kaplan, Sam McCandlish, and Chris Olah. In-context learning and induction heads. *Transformer Circuits Thread*, 2022.

[4] Nelson Elhage, Tristan Hume, Catherine Olsson, Nicholas Schiefer, Tom Henighan, Shauna Kravec, Zac Hatfield-Dodds, Robert Lasenby, Scott Johnston, and Christopher Olah. Toy models of superposition. *Transformer Circuits Thread*, 2022.

[5] Nick Cammarata, Shan Carter, Gabriel Goh, Chris Olah, Michael Petrov, Ludwig Schubert, Chelsea Voss, Ben Egan, and Sweety Ranjan. Thread: Circuits. *Distill*, 2020.

[6] Grégoire Delétang, Anian Ruoss, Jordi Grau-Moya, Tim Genewein, Li Kevin Wenliang, Elliot Catt, Chris Cundy, Marcus Hutter, Shane Legg, Joel Veness, and Pedro A. Ortega. Neural networks and the chomsky hierarchy. In *International Conference on Learning Representations (ICLR)*, 2023.

[7] Mrinank Sharma, Meg Tong, Tomasz Korbak, David Duvenaud, Amanda Askell, Samuel R. Bowman, Esin Durmus, Zac Hatfield-Dodds, Scott R. Johnston, Shauna Kravec, Timothy Maxwell, Sam McCandlish, Kamal Ndousse, Ethan Perez, et al. Towards understanding sycophancy in language models. In *International Conference on Learning Representations (ICLR)*, 2024.