Детерминированный аудит утверждений, написанных языковой моделью

Владимир В. Боровиков
Независимый исследователь
https://orcid.org/0009-0005-7773-3581

Октябрь 2026

Abstract

Языковые модели всё чаще пишут описательную часть исследований: отчёты, вердикты, разделы обсуждения. Опасен при этом не очевидный вымысел, а *правдоподобное преувеличение*: число верно, интерпретация нет, а текст звучит уверенно. Мы описываем протокол, который делает такое преувеличение механически обнаружимым, и сообщаем, что получилось, когда мы применили его к собственному корпусу из 1 416 проб в десяти экспериментальных сериях. Аудит покрывает десять p-значений и двадцать одну дробь; его границы оговорены в разделе 4.

Протокол опирается на шесть требований: заморозка до первой пробы, внешняя память вместо припоминания из контекста, разделение генератора и аудитора, детерминированная сверка каждого приведённого числа, трёхуровневая таксономия ошибок утверждений и состязательный обзор несколькими моделями. Мы предлагаем исполняемый чеклист из двенадцати пунктов и честно сообщаем его статус на собственной работе: шесть пройдено, один исправлен по процедуре, один не пройден, два частично, два требуют человека. Протокол применён не полностью, и чеклист это показывает.

1 Введение

Когда языковая модель описывает эксперимент, текст получается гладким по построению. Гладкость не является свидетельством правильности, но читается как свидетельство — и рецензентом, и автором. В наших сериях мы наблюдали повторяющийся сюжет: первая редакция вердикта утверждала больше, чем позволял архив, и отзывалась только после отдельного пересчёта.

Примеры из наших логов, все проверяемы по открытому репозиторию:

- нулевой результат ($p = 0{,}338$) описан как опровержение «со 100% строгостью»;
- сравнение $2/72$ против $0/72$ названо «законом» (точный критерий Фишера $p = 0{,}4965$ [2]);
- p-значение напечатано как $4{,}81 \times 10^{-13}$, тогда как точный двусторонний критерий Фишера даёт $2{,}909 \times 10^{-18}$, — ошибка инструмента, а не модели, прожившая шесть недель;
- сноска отправляла читателя в файл данных, где не было ни одного из цитируемых байтов.

Последние два случая показательны. Третий породил наш собственный проверяльщик; четвёртый — модель, уверенно написавшая фразу о файле, который не открывала. Ни то, ни другое не поймано вычиткой.

2 Таксономия ошибок утверждений

Мы различаем три яруса, потому что ловятся они по-разному.

Ярус 0 — фабрикация референта. Текст ссылается на объект, которого нет: файл, строку, набор данных, значение. Числа при этом могут быть арифметически безупречны. Ни пересчёт, ни вычитка этого не обнаруживают, потому что пересчитывать нечего. Нужна проверка существования.

Ярус I — интерпретационный перебор. Архив подтверждает число, но не фразу. «$p = 0{,}34$» превращается в «опровергнуто». Лечится переформулировкой.

Ярус II — числовая ошибка. В архиве другое число, чем в тексте. Лечится только пересчётом из лога.

Ярус 0 опаснее всех и защищён слабее всех: у первых двух есть механические проверки, а нулевой исторически держался на одном внимании; протокол добавляет для него механическую проверку существования (П5).

3 Протокол

П1. Заморозка. Код, промпты, гипотезы и эндпоинты хэшируются до первой пробы. Самоподписанный манифест — это декларация, а не заморозка: без доверенной метки времени он доказывает лишь текущее состояние файлов. Мы вводим статус FREEZE-AMENDED для серий, чьи файлы изменились после заморозки, но изменение задокументировано, результат пересчитан и совпал, а регрессионные тесты пройдены. От «аннулировано» он отличается тем, что числа сохраняются, от «заморожено» — тем, что побайтовое воспроизведение пайплайна утрачено.

П2. Внешняя память. Числа читаются из файлов и никогда не припоминаются из контекста. Модель, которая должна помнить, рано или поздно вспомнит неверно.

П3. Разделение контуров. Генератор пишет, аудитор считает. Аудитор независим только тогда, когда написан по отдельной спецификации; «другой скрипт» — это ещё не независимость.

П4. Сверка. Каждое приведённое число — p-значения, дроби, проценты, границы интервалов — пересчитывается скриптом, и вывод скрипта публикуется вместе со статьёй. Два дополнения оказались необходимы на практике. Первое: *тест на заведомо известный ответ* — намеренно испорченный эталон, который проверяльщик обязан отвергнуть, иначе слепой проверяльщик пропускает всё. Второе: статистику нельзя писать с нуля без сверки; проверка, в которой одна самописная реализация сверяется с другой самописной, сравнивает ошибку с ошибкой. Наша реализация критерия Фишера несла абсолютный допуск 10^{-12}, который при $p \approx 10^{-18}$ в $3{,}4 \times 10^{5}$ раз больше самого значения и раздувал хвост на пять порядков. Нашла её независимая реализация, а не протокол, — поэтому сверка теперь обязательный шаг, а не счастливая случайность.

П5. Таксономия. Как в разделе 2, причём Ярус 0 проверяется скриптом, который извлекает из документа пути к файлам и диапазоны строк и проверяет, что цели существуют.

П6. Обзор несколькими моделями. Разные семейства моделей проверяют друг друга. Это самый слабый столп: число проходов — рабочая договорённость, а не доказанный оптимум, а модели, обученные на пересекающихся корпусах, ошибаются коррелированно, поэтому «ансамбль» не гарантирует независимости ошибок.

4 Применение и честный статус

Чеклист состоит из двенадцати пунктов и исполним. На нашем корпусе он показывает:

Статус	Кол-во	Что означает
Пройдено	6	проверено механически
Исправлено	1	правка после заморозки, задокументирована и пересчитана
Не пройден	1	независимость проверяльщика: писал тот же автор
Частично	2	пре-регистрация, версионирование вердиктов
Вручную	2	доверенная метка времени, неизменяемость архива

Единственный непройденный пункт кодом не исправить. Нужен второй автор, который напишет проверяльщик по спецификации, составленной не им. Мы говорим об этом прямо, а не замазываем: чеклист, который можно пройти только соврав, хуже отсутствия чеклиста.

Покрытие П4 — десять p-значений (девять двухвыборочных контрастов и post-hoc пятибиновый тест), двадцать одна дробь и все приведённые проценты, включая границы Клоппера–Пирсона [1]; всё пересчитано двумя независимыми скриптами, совпадение которых проверяется при каждом запуске.

5 Ограничения

Выборка аудита неслучайна: мы проверяли те серии, где аудит проводился. О сериях, которые не проверялись, мы ничего не утверждаем.

Девять гипотез восстановлены по тексту статьи, а не заморожены до прогона. Поправка на множественность (Холм) [3] обсуждается проспективно; к завершённым сериям она не применялась.

Провенанс недоказуем: без доверенной метки времени мы не можем показать, что архив был в нынешнем состоянии *до* прогона, а не приведён к нему после. Доказано более узкое: числа воспроизводятся из архива в том виде, в каком он лежит в репозитории сегодня.

6 Доступность

Код, пробы и исполняемый чеклист: https://github.com/skywhiteangels-cell/llm-token-architect. Сопроводительное исследование: https://doi.org/10.5281/zenodo.23813780.

Идентификация модели. Все приведённые здесь серии проб выполнялись на `flash_lite` — общедоступном тире модели; тексты вердиктов написаны другой моделью общего назначения, что отмечено в архиве проекта. Ничего не скрыто за проприетарными правами или соглашением о неразглашении: архив и скрипты проверки опубликованы под лицензией MIT, поэтому любое число можно пересчитать, не зная, какая модель его произвела.

References

[1] C. J. Clopper and E. S. Pearson. The use of confidence or fiducial limits illustrated in the case of the binomial. *Biometrika*, 26(4):404–413, 1934.

[2] R. A. Fisher. *The Design of Experiments*. Oliver & Boyd, Edinburgh, 1935.

[3] S. Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.